

Fundamentos de IA Generativa e Engenharia de Prompts para o Domínio Industrial

Estudo comparativo de arquiteturas generativas · Biblioteca de prompts técnicos
Geração de 200 registros sintéticos para Digital Twin de motores WEG W22

Modelos Avaliados	Técnicas de Prompting	Registros Sintéticos
3	4	200

Sumário

1.	Mapeamento de Arquiteturas Generativas e Seleção de Modelos	3
1.1	Arquiteturas Avaliadas	3
1.2	Comparativo entre LLMs, Difusão e VAEs	3
1.3	Avaliação dos Três Modelos Seleccionados	4
1.4	Critérios de Seleção e Veredito	5
2.	Engenharia de Prompts Sistemática para o Domínio Técnico	5
2.1	Biblioteca de Prompts Estruturados	5
2.2	Implementação das Quatro Técnicas de Prompting	6
2.3	Avaliação de Qualidade das Respostas	7
2.4	Prompt Guide — Templates Reutilizáveis	8
3.	Geração de Dados Sintéticos para Ampliação do Dataset	9
3.1	Estratégia de Geração em Lote	9
3.2	Regras Físicas e Condicionamento do Prompt	9
3.3	Validação da Qualidade dos Dados Sintéticos	10
3.4	Pipeline e Exportação	10

1. Mapeamento de Arquiteturas Generativas e Seleção de Modelos

Estudo comparativo · Custo computacional · Raciocínio técnico · Execução local vs. API

Nesta seção avaliamos as principais famílias de arquiteturas generativas aplicáveis ao domínio industrial de motores elétricos, com ênfase no projeto de Gêmeo Digital da Forzy. A análise cobriu LLMs (GPT, Llama, Gemma, Qwen), Modelos de Difusão e VAEs, e resultou na seleção fundamentada do modelo primário para geração de dados sintéticos.

1.1 Arquiteturas Avaliadas

Família	Princípio	Pontos Fortes	Limitações
LLMs (GPT, Llama, Gemma, Qwen)	Transformers auto-regressivos com atenção multi-cabeça	Raciocínio encadeado, suporte multilíngue PT/EN, instrução following, geração de texto técnico estruturado	Alto custo de inferência em modelos grandes; necessita GPU para local
Modelos de Difusão (Stable Diffusion, DDPM)	Processo iterativo de remoção de ruído gaussiano em espaço latente	Excelente para dados contínuos (séries temporais de sensores), alta fidelidade distribucional	Complexidade de treinamento; interpretabilidade limitada; não gera texto diretamente
VAEs (Variational Autoencoders)	Encoder-Decoder com espaço latente regularizado por distribuição gaussiana	Compressão eficiente, geração controlada, bom para anomaly detection em séries de sensores	Qualidade de geração inferior a Difusão; tendência a amostras borradas

Tabela 1 — Comparativo de famílias de arquiteturas generativas.

1.2 Comparativo Detalhado: LLMs × Difusão × VAEs para o Domínio Industrial

Para o projeto Forzy — Digital Twin de motores WEG W22 — a escolha da arquitetura principal recai sobre LLMs por três razões centrais: (1) **flexibilidade de tarefa**, pois um único modelo pode interpretar logs de sensores, gerar relatórios de manutenção, responder perguntas técnicas e produzir dados sintéticos em formato CSV; (2) **suporte nativo a PT/EN**, eliminando pipelines de tradução; e (3) **acesso via API gratuita ou de baixo custo** (Groq, Google AI Studio), viabilizando execução no Google Colab sem GPU dedicada.

Modelos de Difusão e VAEs permanecem como alternativas complementares para a fase de ampliação do dataset com séries temporais de vibração e temperatura — tarefas onde a fidelidade distribucional supera a necessidade de raciocínio simbólico.

1.3 Avaliação dos Três Modelos Selecionados

Os três modelos foram instanciados via LangChain e submetidos ao mesmo conjunto de perguntas técnicas, utilizando quatro técnicas de prompting distintas. O critério de verdade (*ground truth*) foi o datasheet oficial do motor WEG W22.

Critério	Llama 3.3 70B (Groq)	GPT OSS 20B (Groq)	Gemini 3.1 Flash Lite (Google)
Custo Computacional	API Groq — gratuita até limite de tokens	API Groq — gratuita até limite de tokens	API Google AI Studio — gratuita (cota generosa)
Raciocínio Técnico	★★★★★ Excelente — zero alucinação física nos testes	★★★██ Aluciou parâmetros (25 °C / 125 °C)	★★★★█ Muito bom — cruzou com Classe F de isolamento
Suporte PT/EN	✓ Excelente bilíngue	✓ Bom bilíngue	✓ Excelente bilíngue
Execução Local vs. API	API Groq (Colab) Local: requer GPU A100	API Groq (Colab) Local: viável em GPU menor	API Google (Colab) Local: não disponível
Acurácia Factual (vs. datasheet)	100%	~70% (falhas no Role-Playing)	100%
Compleitude	Alta — cobre todos os campos pedidos	Média — omite parâmetros em respostas curtas	Muito alta — adiciona contexto normativo
Consistência Terminológica	Alta	Baixa (mistura unidades)	Alta
Veredicto	█ SELECIONADO Primeiro modelo (dados sintéticos)	█ REPROVADO Inviável para uso preditivo	█ APROVADO Segundo modelo (assistente conversacional)

Tabela 2 — Avaliação comparativa dos três modelos testados.

1.4 Critérios de Seleção e Veredito Final

O **Llama 3.3 70B** foi selecionado como motor principal para a geração dos 200 registros sintéticos por garantir **zero alucinação física** e máxima fidelidade terminológica ao datasheet do WEG W22 — requisito crítico para integridade do Gêmeo Digital.

O **Gemini 3.1 Flash Lite** permanece como segunda opção para o assistente conversacional final, graças à sua capacidade de correlacionar dados com normas técnicas (ex.: Classe de Isolamento F). O **GPT OSS 20B** foi reprovado: alucinou limites de temperatura (25 °C / 125 °C não presentes no manual), o que poderia causar falhas reais na planta industrial.

█ **Veredito: Role-Playing + Chain-of-Thought geram o maior valor de negócio, mas exigem modelos robustos. O Llama 3.3 70B é a escolha segura para dados sintéticos; o Gemini Flash Lite complementa nas camadas de raciocínio normativo.**

2. Engenharia de Prompts Sistemática para o Domínio Técnico

Biblioteca de prompts · 4 técnicas · Avaliação de qualidade · Prompt Guide

A biblioteca de prompts foi desenvolvida para cobrir as quatro tarefas centrais do projeto Forzy: interpretação de dados de sensores, diagnóstico de falhas, geração de instruções de manutenção e tradução de terminologia técnica. Todas as técnicas foram testadas com contexto RAG (*Retrieval-Augmented Generation*) alimentado pelo datasheet oficial.

2.1 Biblioteca de Prompts Estruturados

Tarefa	Template de Prompt	Variáveis
Interpretação de Sensores	Contexto técnico: {contexto} Analise os seguintes dados de sensor do motor WEG W22 e identifique anomalias com base nos limites do datasheet: Temperatura: {temp}°C Vibração: {vib} mm/s Corrente: {corr} A	{contexto}, {temp}, {vib}, {corr}
Diagnóstico de Falhas	Você é um Engenheiro de Manutenção Sênior da Forzy. Com base no histórico: {historico} Diagnostique a causa-raiz e classifique a criticidade (Alta/Média/Baixa).	{historico}
Instrução de Manutenção	Pense passo a passo e gere uma Ordem de Serviço completa para o seguinte problema: {descricao_falha} Inclua: EPI necessários, ferramentas, procedimento e checklist de retorno à operação.	{descricao_falha}
Tradução de Terminologia	Exemplo 1: 'locked rotor time' → 'tempo de rotor bloqueado'. Exemplo 2: 'insulation class F' → 'classe de isolamento F'. Traduza e explique o termo técnico: {termo_en}	{termo_en}

Tabela 3 — Biblioteca de prompts para as quatro tarefas do domínio industrial.

2.2 Implementação das Quatro Técnicas de Prompting

A função **prompt_tec()** implementada no notebook aplica sistematicamente as quatro técnicas abaixo a cada modelo, usando o contexto recuperado pelo banco vetorial FAISS (*mxbai-embed-large-v1*) como grounding factual.

Técnica	Template utilizado	Quando usar
Zero-Shot	"Responda diretamente: {pergunta}"	Triagem rápida, perguntas objetivas com resposta única
Few-Shot	"Exemplo 1: Potência? R: 2.2 kW. Exemplo 2: Frequência? R: 60 Hz. Pergunta: {pergunta}"	Padronização de formato de saída; extração de campos específicos

Chain-of-Thought (CoT)	"Pense passo a passo analisando o manual técnico e depois responda: {pergunta}"	Diagnósticos complexos; análise multi-critério; raciocínio causal
Role-Playing (Persona)	"Você é um Engenheiro de Manutenção Sênior da Forzy. Responda com rigor técnico: {pergunta}"	Geração de relatórios formais; ordens de serviço; pareceres técnicos

Tabela 4 — Quatro técnicas de prompting implementadas e seu contexto de uso.

2.3 Avaliação de Qualidade das Respostas

A avaliação foi conduzida com três métricas principais verificadas manualmente contra o datasheet WEG W22:

Modelo	Técnica	Acurácia Factual	Completo e	Consistência Term.
Llama 3.3 70B	Zero-Shot	100%	Alta	Alta
Llama 3.3 70B	Few-Shot	100%	Alta	Alta
Llama 3.3 70B	CoT	100%	Muito Alta	Alta
Llama 3.3 70B	Role-Playing	100%	Muito Alta	Alta
GPT OSS 20B	Zero-Shot	100%	Média	Média
GPT OSS 20B	Few-Shot	100%	Média	Média
GPT OSS 20B	CoT	100%	Média	Baixa
GPT OSS 20B	Role-Playing	~70%	Baixa	Baixa
Gemini Flash Lite	Zero-Shot	100%	Muito Alta	Alta
Gemini Flash Lite	Few-Shot	100%	Muito Alta	Alta
Gemini Flash Lite	CoT	100%	Muito Alta	Alta
Gemini Flash Lite	Role-Playing	100%	Muito Alta	Alta

Tabela 5 — Avaliação de qualidade por modelo e técnica (linha vermelha = falha crítica).

2.4 Prompt Guide — Templates Reutilizáveis

- **REGRA 1 — Contexto RAG sempre presente:** Prefixar todo prompt com '*Contexto técnico: {contexto}*' alimentado pelo retriever FAISS para ancorar o modelo no datasheet oficial e eliminar alucinações.
- **REGRA 2 — Tarefas de diagnóstico → CoT + Role-Playing:** Combinar as duas técnicas maximiza raciocínio causal e rigor terminológico. Template: '*Você é um Eng. de Manutenção Sênior. Pense passo a passo e diagnostique: {problema}*'.
- **REGRA 3 — Extração de campos → Few-Shot:** Fornecer 2 exemplos no formato desejado força o modelo a replicar a estrutura de saída, reduzindo pós-processamento.

-
- **REGRA 4 — Geração de dados sintéticos → Role-Playing + Regras Físicas explícitas:** Incluir limites numéricos do datasheet como restrições hard no prompt (ex.: '*Temperatura Normal: 50–90 °C*') é mandatório para fidelidade física.
 - **REGRA 5 — Temperatura controlada:** Usar `temperature=0.1` para extração factual; `temperature=0.7–0.9` para geração sintética com diversidade; `top_p=0.95` como padrão.
 - **REGRA 6 — Formato de saída explícito:** Especificar sempre o formato esperado no prompt (CSV, JSON, lista numerada) evita variações de formatação entre execuções.

3. Geração de Dados Sintéticos para Ampliação do Dataset

200 registros · Regras físicas · Validação estatística · Pipeline reproduzível

Esta seção descreve o pipeline de geração, as regras de condicionamento físico aplicadas e os critérios de validação dos 200 registros de manutenção sintéticos produzidos para o Gêmeo Digital do motor WEG W22.

200

Registros Gerados

10×20

Blocos de Geração

80%

Distribuição Normal

20%

Distribuição Falha

3.1 Estratégia de Geração em Lote

A geração foi estruturada em **10 blocos de 20 registros**, cada bloco correspondendo a uma chamada independente à API Groq com o modelo Llama 3.3 70B. Essa abordagem em lote tem três vantagens: (1) respeita os limites de tokens por requisição da API; (2) permite paralelização futura; e (3) facilita reexecução seletiva em caso de falha de bloco.

Código-chave do pipeline:

```
prompt_sintetico = ChatPromptTemplate.from_template("""\nBaseado no datasheet do motor WEG fornecido, gere 20 registros sequenciais de logs de\nmanutenção em formato CSV.\nCada linha deve conter: Data, Temperatura (°C), Vibração (mm/s), Status, Descrição Técnica.\n...[regras físicas]...\n""")\n\nfor i in range(10):\n    resposta = dataset_chain.invoke({})\n    todos_os_registros.append(resposta.content)
```

3.2 Regras Físicas e Condicionamento do Prompt

Status	Temperatura (°C)	Vibração (mm/s)	Fundamento Técnico
Normal	50 – 90 °C	0.4 – 1.8 mm/s	Limites operacionais datasheet WEG W22; Classe de Isolamento F (máx. 155 °C)
Falha — Sobreaquecimento	110 – 145 °C	Normal (0.4–1.8)	Temperatura acima de 90 °C indica sobrecarga ou falha de ventilação; acima de 155 °C → derretimento do isolante
Falha — Vibração Grave	Normal (50–90)	3.5 – 7.0 mm/s	Desalinhamento grave de eixo ou rolamento quebrado — ISO 10816 classe III

Tabela 6 — Regras físicas implementadas no prompt de geração sintética.

Parâmetros de condicionamento (temperatura, top-p, formato):

- Modelo: **llama-3.3-70b-versatile** via Groq (max_tokens padrão da plataforma)
- Temperature: **0.7** — balanceia diversidade de cenários com fidelidade física
- Top-p: **0.95** — evita tokens improváveis que geram grandezas inválidas

- Formato de saída: **CSV sem cabeçalho** em cada bloco, consolidados em arquivo único
- Campos obrigatórios: Data (YYYY-MM-DD), Temperatura (°C), Vibração (mm/s), Status, Descrição Técnica

3.3 Validação da Qualidade dos Dados Sintéticos

Os critérios de validação aplicados garantem que o dataset sintético seja seguro para treinar algoritmos de detecção de anomalias sem introduzir vieses físicos:

Critério de Validação	Método	Resultado Esperado
Distribuição estatística compatível com dados reais	Histogramas de Temperatura e Vibração; comparação com faixas do datasheet	80% registros em faixas normais; 20% em faixas de falha
Ausência de alucinações factuais	Verificação manual: todos os valores de Temperatura e Vibração dentro das faixas definidas nas regras físicas	0 registros com valores impossíveis (ex.: 200 °C ou -5 mm/s)
Coerência de unidades e grandezas	Inspeção de padrão regex no CSV; verificação de tipo de coluna pós-parse	Todas as colunas numéricas parsáveis sem erros de conversão
Diversidade temporal	Análise da coluna Data: distribuição uniforme ao longo do ano 2024	Registros distribuídos em ao menos 8 meses distintos
Qualidade das Descrições Técnicas	Revisão de amostra de 20 registros: terminologia alinhada ao vocabulário do datasheet	Terminologia correta (ex.: 'sobreaquecimento por sobrecarga', 'desbalanceamento de rotor')

Tabela 7 — Critérios de validação dos dados sintéticos.

3.4 Pipeline Completo e Exportação

O pipeline de geração é totalmente reproduzível no Google Colab e segue as etapas:

1. Configuração de APIs	Carregamento de GROQ_API_KEY e GOOGLE_API_KEY via <code>userdata.get()</code> ; instanciação dos três modelos.
2. Construção do Banco Vetorial	Download do PDF do datasheet WEG W22; chunking via <code>PyPDFLoader</code> ; embedding com <code>mxbai-embed-large-v1</code> ; indexação <code>FAISS</code> .
3. Testes de Prompt Engineering	Execução da função <code>prompt_tec()</code> com a pergunta-teste sobre tempo de rotor bloqueado; avaliação comparativa.

4. Seleção do Modelo	Veredito: Llama 3.3 70B selecionado com base em acurácia 100% e zero alucinação.
5. Geração em Lote	Loop de 10 iterações × 20 registros = 200 registros totais com regras físicas no prompt.
6. Exportação CSV	Consolidação de todos os blocos em dados_sinteticos_sprint1.csv com encoding UTF-8.

■ **Resultado:** Arquivo *dados_sinteticos_sprint1.csv* com 200 registros rotulados, fisicamente coerentes, prontos para treinar os algoritmos de detecção de anomalias do Gêmeo Digital da Forzy. O processo é totalmente reproduzível — basta reexecutar o notebook com as chaves de API válidas.

Artefatos entregues: GENAI_S1.ipynb (notebook executado) · dados_sinteticos_sprint1.csv (200 registros) · Este documento (Prompt Guide + Seleção de Modelos)